

ChronicCare-Agent 技术报告

交付日期：2026年8月10日

摘要

ChronicCare-Agent 是一个基于 Nexent、DataMate 和 Ascend NPU 的慢病随访“数据—知识—洞察”智能体。项目使用 Nexent 单智能体作为自然语言入口，通过 MCP Adapter 调用数据处理、知识图谱、受控 Open SQL、统计分析和可视化工具；DataMate 负责可组合的数据处理算子链路；知识图谱组织患者、疾病、随访、检验、药物、风险和生活方式关系；NPU 增强分支加速实体与关系阶段中的 BGE 推理热点。

当前交付版使用参考真实慢病随访业务的字段结构、业务关系和合理取值范围，采用程序化规则与固定随机种子合成的 2,000 名患者数据，包含 8,231 条随访记录、131,323 条检验记录和 18,248 条用药记录，覆盖 20 种慢病。知识图谱包含 197,404 个节点、396,928 条边、14 类实体和 15 类关系。项目提供 240 题 NL2SQL 盲测集和外部模型调用评测入口；SQL Guard 在 120 例安全评测中达到 100%。

安全边界：本项目仅用于慢病随访数据处理、知识组织和辅助分析，不提供临床诊断，不替代医生决策。

1. 项目背景与目标

慢病随访数据具有持续时间长、数据来源多、患者共病普遍和指标关联复杂等特点。单纯表格查询难以回答跨患者、疾病、检验、药物和风险的关联问题；完全依赖大模型自由生成，又可能造成统计口径不稳定、SQL 不安全或结果不可追溯。

本项目的目标是：

1. 建立可由智能体理解、规划和执行的数据处理算子链路。
2. 自动构建医疗领域知识图谱，并提供实体、关系、路径和子图问答。
3. 在统一数据与图谱基础上完成统计、关联、趋势、Open SQL 和图文可视化分析。
4. 将适合并行计算的 BGE 推理热点迁移到 Ascend NPU，并提供公平、可复核的 CPU/NPU 实测。
5. 通过确定性工具、SQL Guard、真实 Observation 和证据产物降低大模型幻觉风险。

2. 总体方案

系统由以下层次组成：

- 交互与规划层：Nexent 单智能体理解用户问题，并按提示词约束选择最合适的 MCP 工具。
- 工具协议层：MCP Adapter 将后端接口包装为带输入输出契约的工具。
- 业务服务层：Tool Server 提供数据统计、图谱、Open SQL、DataMate、DAG、NPU 和 artifacts 服务。
- 数据处理层：DataMate 11 个主线算子与动态 DAG 完成接入、清洗、抽取、校验、图谱、SQLite 和报告处理。
- 知识与分析层：SQLite 支撑确定性统计和 Open SQL；知识图谱支撑跨实体关联、证据和子图。
- 可视化层：生成表格、柱状图、饼图、折线图、图谱预览和交互式 HTML。
- 硬件加速层：两个 NPU 增强算子执行 BGE embedding 标准化和关系重排。

详细模块关系见 [系统架构](#)。

3. 任务一：数据处理智能体

3.1 DataMate 算子

系统提供 11 个 CPU/通用主线算子：

分组	算子	作用
数据清洗	<code>chronic_file_ingest</code>	文件接入
数据清洗	<code>chronic_table_clean</code>	表格清洗
数据清洗	<code>chronic_field_normalize</code>	字段标准化
数据清洗	<code>chronic_text_split</code>	文本切分
知识图谱	<code>chronic_entity_extract</code>	实体规则抽取
知识图谱	<code>chronic_relation_extract</code>	关系规则抽取
知识图谱	<code>chronic_triple_validate</code>	三元组校验
知识图谱	<code>chronic_kg_build</code>	图谱构建
数据分析	<code>chronic_sqlite_loader</code>	SQLite 加载
数据分析	<code>chronic_nl2sql_analyze</code>	NL2SQL 分析
数据分析	<code>chronic_report_pack</code>	报告打包

算子通过明确的输入输出契约组合，执行状态和耗时可追踪。Nexent 前端提出“请重新执行 DataMate 算子链路”时，系统必须真实运行本轮链路并等待 Observation，不能读取旧报告直接回答。

3.2 动态 DAG

动态 DAG 将用户目标转换为所需算子的最小依赖图。它支持：

- 只生成计划而不执行；
- 只清洗、只重建知识图谱、只刷新分析库或执行完整链路；
- 启用或关闭 NPU 增强分支；
- 节点级状态、错误、重试和断点恢复；
- 输入或版本变化后的缓存失效。

该设计使 Agent 不必为每个流程维护固定脚本，也避免在只需局部结果时运行完整链路。

4. 任务二：知识图谱问答智能体

4.1 图谱模式

当前图谱覆盖 14 类实体，包括患者、疾病、随访、检验结果、指标、药物、药物类别、风险事件、随访计划、生活方式、医嘱和风险评分等；覆盖 15 类关系，包括患者患病、患者随访、随访检验、检验归属指标、指标异常风险、疾病关联指标、随访用药、药物类别和疾病用药等。

图谱规模如下：

指标	数值
节点	197,404
边	396,928
实体类型	14
关系类型	15
精确重复边	0
边来源信息完整率	100%

4.2 构建与问答

规则抽取首先保证确定性覆盖，BGE 分支用于候选标准化和重排，随后三元组校验拒绝非法实体引用和关系类型。构建完成后，系统提供：

- 图谱规模和类型概览；
- 疾病关联指标、药物和风险查询；
- 两个实体间的关系证据；
- 患者路径查询；
- 疾病、疾病组合和关系主题的实时子图；
- 图谱预览和可交互 HTML。

全局概览不在浏览器直接加载约 20 万节点，而是展示规模与类型摘要；需要分析时再按问题生成有限子图，兼顾可用性和可解释性。

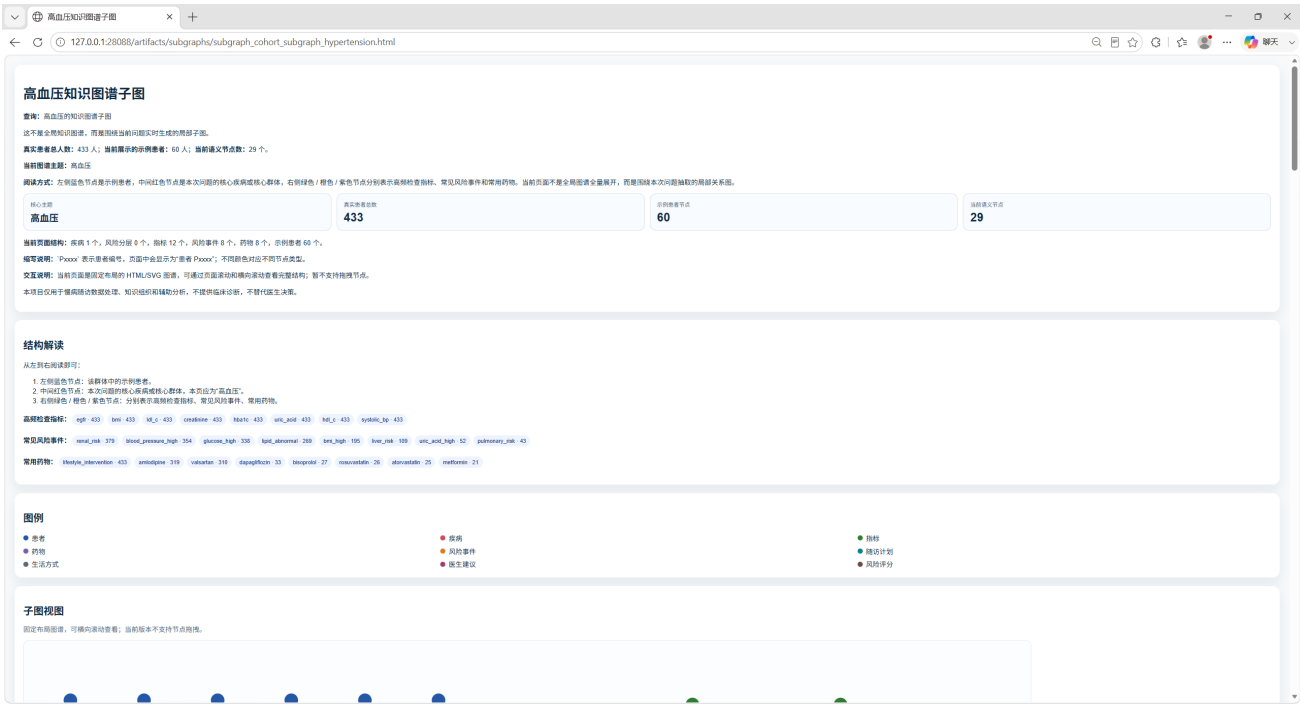


图1 高血压知识图谱实时子图概览

5. 任务三：数据分析与图谱驱动可视化

5.1 专用统计工具

对于数据规模、疾病分布、共病组合、风险分层和未来高风险随访等高频问题，系统使用职责单一的确定性工具。工具直接读取当前 SQLite 或图谱，返回统计口径、表格和可选图表，避免大模型自行计算。

5.2 受控 Open SQL

对于非固定问句，系统采用：

1. 意图识别；
2. Schema Linking；
3. 模板优先、可选 LLM 候选 SQL；
4. SQL AST Guard；
5. 只读 SQLite 执行；
6. 结果解释和 trace。

当前 Open SQL 提供 9 张白名单表和 16 个白名单 JOIN。Guard 禁止 DDL、DML、多语句、危险函数、系统表、非白名单字段和非法 JOIN。LLM 只生成候选 SQL，不具备绕过安全校验的权限。

算子	CPU 2,048 条（5轮均值）	NPU 2,048 条（5轮均值）	同样本加速比	NPU 全量（5轮均值）
实体标准化	2.822746 秒	0.211415 秒	13.3517×	174,564 条，14.418135 秒
关系重排	4.599725 秒	0.283731 秒	16.2116×	374,088 条，52.263966 秒

上述数值来自 `outputs/evaluation/npu_operator_benchmark_report.json`。两算子的CPU与NPU均使用同一批 2,048条样本，在物理6号Ascend 910B3上独立执行5轮，并以CPU平均耗时除以NPU平均耗时计算加速比；报告同时保留每轮原始值。Nexent前端展示的是某一次即时运行，技术报告采用5轮后端实测的算术平均值，因此两者可能不同；共享服务器负载、预热和测量时点也会造成合理波动，正式结论以机器可读报告中的5轮均值为准。

7. Nexent 前端代表性问答

以下20个问题构成当前Nexent前端验证集，答案均来自对应工具的Observation。

编号	前端问题	正确结果或展示重点
1	现在 ChronicCare 支持哪些算子?	11 个 CPU/通用主线算子, 分为数据清洗、知识图谱和数据分析三组; 另有2个NPU增强算子
2	请重新执行 DataMate 算子链路	真实运行11个主线算子, 返回本轮状态、逐算子耗时、图谱和分析产物
3	运行全流程并输出真实2048条CPU/NPU同样本对比和NPU全量结果	三列独立实测、CPU64线程、NPU batch1024、各预热一次、无 fallback
4	现在有多少患者、随访记录、检验记录?	2,000人、8,231条随访、131,323条检验; 同时可展示18,248条用药和图谱规模
5	当前常见病有哪些?	20种疾病; 高血压433、糖尿病356、高脂血症328等, 比例分母为2,000名唯一患者
6	高血压患者有多少?	433人, 占21.65%
7	不同疾病组合的人数分布是多少?	多病共病患者782人; 展示精确组合Top 12
8	当前不同风险等级人数是多少?	高风险859、中风险905、低风险236, 总计2,000
9	未来30天高风险随访患者有多少并给出趋势?	68名去重患者, 展示数据库中确定随访日期对应的30天逐日分布
10	未来67天高风险随访患者有多少并给出趋势?	165名去重患者, 展示67天逐日分布
11	最近6个月血压异常人数趋势如何?	展示2026年2—7月检测人数、异常记录和异常率, 异常率约48.54%—51.47%
12	当前知识图谱有多少节点、边、实体类型和关系类型?	197,404节点、396,928边、14类实体、15类关系; 链接打开概览页面?
13	高血压关联哪些检查指标、药物和风险事件?	覆盖433名高血压患者, 分别列出图谱关联指标、药物和风险
14	生成高血压知识图谱子图	实时子图覆盖433条高血压患者记录, 页面展示抽样患者节点和语义节点
15	生成高血压合并糖尿病群体子图	高血压与糖尿病标签交集患者56人, 生成组合疾病子图
16	画出高盐饮食和血压异常关系并说明证据	高盐饮食相关患者418人、血压检验3,401条、异常比例28.79%; 异常交集患者262人
17	画出糖尿病、HbA1c、用药和风险事件关系图	覆盖356名糖尿病患者, 展示指标、药物、风险和患者样本节点
18	只重建知识图谱时如何规划DAG, 不执行	返回裁剪后的节点、依赖、跳过原因和风险, 不修改产物
19	列出Open SQL支持表、字段、JOIN和安全规则	9张白名单表、16个白名单JOIN, 只允许受控SELECT
20	高血压合并糖尿病患者平均HbA1c是多少, 并展示SQL和Guard	56名患者、224条HbA1c记录、平均7.0517%, 前端显示7.05%; Guard通过

对应的42张前端截图见 [前端证据索引](#)。

8. 测试结果

- 自动化测试共437项全部通过，包括431项默认单元、契约与集成测试，以及6项显式开启的真实服务、DataMate容器和Ascend NPU烟测。
- 按 analysis、kg、mcp_adapter、orchestration、runtime_common、tool_server 和 visualization 统一统计，语句与分支综合覆盖率为62.32%，其中语句覆盖率65.61%、分支覆盖率53.64%。
- 重点模块覆盖率包括：MCP HTTP客户端、MCP Adapter客户端和问题流水线100%，问题分类器98.39%，动态DAG引擎98.13%，图谱总览渲染95.48%，图表渲染93.20%，报告入口91.49%，Supervisor编排90.00%，查询规划（orchestration/planner.py）86.49%，NPU runtime（runtime_common/npn_runtime.py）86.36%，Open SQL工具服务（tool_server/open_sql_tools.py）84.62%，DataMate流水线工具81.82%，MCP聚合入口（mcp_adapter/server.py）51.51%。
- Ruff静态检查全部通过。真实集成测试仅执行只读服务调用、DataMate单行临时输入和NPU最小张量计算，不运行耗时的全量基准。
- NL2SQL本地固定工程回归盲测：240题，正确239题，总执行结果准确率99.58%。
- 真实外部LLM候选：80题，正确79题，准确率98.75%，调用失败和超时均为0。
- 复杂查询30/30、模板查询80/80、安全自然语言25/25、不支持问题25/25。
- 意图识别、Schema Linking、SQL语法成功率和Guard正确率均为100%。
- 不支持问题子集为25/25；按当前固定子集评测脚本口径，Precision、Recall和F1均为100%。
- 唯一失败来自“就诊事件规模”的统计口径歧义：候选按去重患者计数，Gold按去重就诊事件计数。
- KGQA工程测试：150例，精确准确率、证据命中率和不可回答拒答准确率均为100%。该结果是工程回归，不代表独立临床语义评审。
- Agent路由回归：80个问题，当前报告通过率100%。
- 动态DAG验收覆盖规划、执行、重试、恢复和NPU不可用fallback场景。

完整方法和边界见 [测试与性能报告](#)。

9. 创新与落地价值

9.1 技术创新

- 用单Agent统一数据处理、图谱、Open SQL和NPU工具，同时通过专用路由减少工具误选。
- 动态DAG按照目标裁剪算子，并支持节点级恢复。
- 图谱确定关系边界，SQLite计算真实人群证据，兼顾语义关联和统计准确性。
- LLM候选SQL必须经过AST级SQL Guard，降低开放式分析风险。
- 只迁移BGE模型热点到NPU，避免把不适合NPU的规则算子强行迁移。

9.2 业务价值

- 支持慢病患者规模、共病组合、风险分层、未来随访和长期指标趋势分析。
- 通过图谱把疾病、指标、药物和风险证据组织为可解释关系。
- CPU环境可运行主线能力，NPU环境可提升模型推理吞吐。
- 模块化工具和算子便于扩展疾病、分析问题、图谱关系和可视化组件。

9.3 开源工程与可复现交付

- 开源仓库与发布版本如下：

工程	GitLink仓库	发布分支	版本标识
ChronicCare-Agent	guotingxuan/ChronicCare-Agent	competition	以 competition 分支HEAD为准
DataMate算子贡献	guotingxuan/DataMate	competition	5ef1f9619850fe3b640231784e4c9d2e6ce4ae56

- ChronicCare-Agent仓库提供完整智能体工程，DataMate仓库的 competition 分支提供慢病数据处理与NPU增强算子；复现时应使用表中对应分支。
- 项目提供 LICENSE、NOTICE、THIRD_PARTY_NOTICES.md 和依赖清单，说明开源协议与第三方组件来源。
- 通过 requirements.txt、Docker Compose配置、环境变量模板和部署文档固定运行入口与关键依赖。
- 单元测试、契约测试、集成测试、真实服务烟测和静态检查共同构成可重复的质量验证链路。
- 交付清单、任务要求映射、数据与模型来源说明、API契约和测试报告共同提供代码、数据、模型、接口与评测结果的可追溯关系。
- Nexent集成基线为 v2.2.0（commit [a57538fb68e23d4e6b5439c3f13add014edbfd7e](#)），DataMate集成基线为commit [6136834ce00075f0a844e26dcc7fe1cc9e0d8dd9](#)；项目通过MCP和独立算子目录集成上游能力。

详细合规说明见[开源合规说明](#)，部署与复现方式见[部署指导](#)。

10. 限制与后续工作

- 当前数据为参考真实慢病随访业务的字段结构、业务关系和合理取值范围，采用程序化规则与固定随机种子合成的数据，不包含可识别的真实患者身份信息，不能代替真实临床验证。
- KGQA为工程规则集评测，不宣称医疗专家语义准确率。
- CPU侧没有整机功耗采样，当前不能做CPU/NPU严格能效比较。
- LLM候选在“事件规模”等歧义表达上仍可能混淆患者人数与记录数量，需要通过统计语义约束和结果结构校验进一步收敛。

- 大规模全局图谱不适合浏览器直接渲染，因此采用概览和按需子图。
- 外部Nexent、DataMate、模型权重和Ascend软件栈需要按各自许可证与环境要求部署。